

男 · 22 岁 · 中共党员 · 本科（软件工程） · 现居上海 · 英语 CET-4

个人优势

PROFILE

交付过 0→1 的医疗 AI Agent 平台并主导其「Web 多租户 → 合规驱动的桌面本地执行」架构转型，Go、Python、TypeScript 三栈均有万行级生产实产。AI 应用工程链路完整：多 Agent 编排、模型路由与 fallback、RAG、LoRA 微调与评估，到 API Key 按人签发与用量计量的成本治理；并以自研 Go 压测工具与负反馈内存控制器解决平台容量与 OOM 问题。

工作经历

EXPERIENCE

2026.05 至今 上海杰诺生物科技有限公司 / 全栈工程师

量子链 · 医疗 AI Agent 工作台（0→1 自研）—— 面向临床研究的 Agent 平台，支持 SAE 报告生成、CRF 核查等医疗 workflow。

阶段 01 Web 版工作台：Go 控制面 + Agent 网关

- 从 0 参与搭建 Go/Gin 控制面（85 文件 / 1.6 万行 / 105 接口）与独立 Agent 网关 supervisor：企微扫码与账密双登录、每 workflow 独立 Agent 实例、每任务独立工作目录与产物回收，并打通 workflow 市场「发布 → 审批授权 → 成员使用」全链路。
- 多模型接入与分级路由：将 deepseek / qwen / zai 统一抽象为 openai-completions + baseUrl，建立「全局默认 → 单技能覆盖 → 部门白名单」三层模型偏好与 fallback 自动降级。
- API Key 池化与百炼按人动态签发：将共享企业 Key 重构为一人一把、可回收的池化分配；接入阿里云百炼 ModelStudio OpenAPI 现场签发专属 Key（留存云侧 apiKeyId 对账、离职真实调用 DeleteApiKey 释放配额位），一把 Key 通吃 qwen / deepseek / glm —— 解决共享凭据无法定位泄露源、无法按人撤销与计量的根本缺陷。
- 稳定性与容量：分片上传 + 断点续传 + 超时自愈、SSH 隧道保活与连接池；设计恒温器式内存控制器（以内核 MemAvailable% 与 PSI 为反馈量，systemd MemoryHigh 软限 + 加解限迟滞带）根治执行节点 OOM；自研零依赖 Go 压测工具以 N 个独立账号模拟真实多人并发，定位各层并发拐点。

阶段 02 合规驱动的架构转型：桌面客户端 + 模型本地化

- 因医疗数据不得出内网，主导将 Web 版重构为桌面本地执行架构：Electron（主/预加载/渲染三层隔离）+ React 19 + Vite，任务在用户本机 WSL2 内完成、数据不出网；关闭 nodeIntegration、开启 contextIsolation 与 sandbox，系统能力经预加载层 IPC 白名单暴露；并实现执行前自动脱敏、回传按 token 还原的 fail-closed 脱敏链路。
- 牵头模型本地化部署方案：针对临床原始记录与病历 PDF 出境公网 API 的合规风险，依托既有 OpenAI 兼容抽象论证「本地推理服务即第四个 provider」—— vLLM / SGLang / Ollama 仅需新增 provider 条目与内网 baseUrl，不改业务代码；借单技能模型偏好实现敏感技能走本地、普通对话走云的分级路由，并禁止敏感技能配置云端 fallback 以防绕过合规。
- 自研 WSL2 一键装机链路（导入 Ubuntu rootfs → 创建 AgentScope 运行时 → 部署后端 → 健康检查），全程免管理员权限；定位并根治四个平台级缺陷——WSL 未会话结束回收后台进程、Windows → wsl.exe 的 argv 传参破坏脚本内容（改走 stdin 注入）、uvicorn 仅绑 IPv4 而 Chromium 优先解析 ::1、mirrored 网络需下发 Hyper-V 防火墙规则，将「装完却连不上」的偶发故障收敛为可复现并彻底修复。

技术栈 Go / Gin | Python / FastAPI / SQLite | TypeScript / React 19 / Vite / Electron | WSL2 / systemd / Nginx | AgentScope / pytest

2025.11 2026. 足下科技有限公司 / AI 产品经理

- 主导 AIknowledge 产品优化，引入流式输出、上下文管理优化、模型路由、多 Agent 规划及思维链技术，将产品从 AI 对话工具升级为可用的公司内部材料编辑助手，并完成企业知识库产品规划支撑商业化拓展。
- 调研汽车行业竞品与国标政策，推动 ADR、OTA 两项产品立项；任年度大版本 V1.17.1 发版总负责人，统筹需求冻结至上线全流程，上线后 72 小时内完成首个补丁包修复。

2025.03 2025. 南京国睿科技睿行数智 / 产品经理

- 负责需求分析、PRD 撰写与原型设计并组织评审推动落地；参与应急处置 AI Agent 方案设计与原型输出，组织评审测试（业务测试集准确率超 80%）并推动方案在 V2 版本投入使用；另负责乘务管理系统核心模块的流程优化与交互原型，保障系统终验与按时上线。

项目经历

PROJECTS

2026.03 2026.06 Rapibala 社区 · AI 学习型社区平台 / 负责人 · 全栈

面向 AI 研究者与开发者的知识社区，按商业级前后端分离与 1000+ 并发在线目标设计。Vue 3 + TS 前端 5.0 万行 / 20 视图，Fastify + Prisma + PostgreSQL + Redis 后端 2.8 万行 / 70 数据模型 / 339 API。

- WebGPU 端侧推理：笔记编辑器用 compute shader 做 on-device 幽灵文本预测，JS n-gram 作降级路径，以零往返延迟、零 token 成本、数据不出端同时满足体验与隐私。
- 高并发治理与异步化：引入 PgBouncer transaction mode 确立「应用查询走池化、管理流量走直连」双通道；热点路径缓存键统一收口，搜索做查询归一化与 Redis 短 TTL 缓存；以 BullMQ 将笔记审计、通知、搜索投影与视频转码移出主路径；并实现 AI 密钥池、并发控制、限流与用量计量四层成本治理。

2025.092025.09

声医司元 · AI 中医健康监测助手 / 负责人

LIC·2025 语言与智能技术竞赛 · 智慧医疗赛道

■ 拆解中医「望闻问切」场景，将舌象、面象与语音问诊多模态体征交叉验证生成诊断依据；设计「长期体质画像 + 短期动态症状库」双层记忆引擎，突破上下文窗口限制实现跨会话连续化管理。

■ 主导构建 Neo4j 中医知识图谱（体质、症状、证候、方剂、药性及禁忌）并设计动态槽位填充反问流程，用户提供超 3 条症状时反问准确率超 90%；制定 QLoRA 微调方案，微调模型在自建医学问题集上较原模型（50%）提升约 31%，100 题测试集推动 Agent 回答正确率提升 78% 以上。

2026.012026.01

医疗实体抽取与断言训练框架 / 负责人

■ 零样本医疗 NER + 四类断言分类流水线（18 模块 / 7,100 行 / 9 阶段，内置 6 万节点、35 万三元组知识图谱）：以「预学习 → LLM 抽取（提示 + 反思）→ 知识图谱扩展 → 规则过滤归一化」四步流程取得 CMeEE-V2 Micro F1 0.631、IMCS-V2 归一化后 0.711。

■ 基于 MacBERT 微调断言分类器，以 FocalLoss + FGM 对抗训练 + 类权重 + 实体标记解决样本不平衡，CMeEE / IMCS 测试集 Macro F1 0.878 / 0.89；test split 全程不参与训练并按文档分组划分验证集，严格防泄露。

2026.072026.07

3D · 图文联合 3D 生成 / 个人项目

■ 基于混元 3D 的图文联合生成：图像与文字 tokens 拼接为同一条件序列单次生成模型，再以六维一致性自检（几何维度在网格上真实测量）驱动有界迭代修正；三套同接口适配器解耦模型后端，无 GPU 亦可全链路测试。

专业技能	SKILLS
后端	Go (Gin)、Python (FastAPI)、Node.js (Fastify)；三栈均有万行级生产实产，累计交付 480+ HTTP 接口
前端	React 19 / Vue 3 / TypeScript / Vite / Pinia；Electron 桌面端工程化（三层隔离与 IPC 白名单）
数据与 AI	PostgreSQL (Prisma / PgBouncer)、SQLite、Redis、Neo4j、FAISS、DuckDB；多 Agent 编排、RAG、模型路由与 fallback、LoRA/QLoRA 微调与评估、AgentScope / LangChain
系统与质量	Linux 系统级排障（/proc 内存指标与 PSI、双栈解析、防火墙）、systemd cgroup 内存治理、WSL2、Docker、Nginx、BullMQ；pytest / vitest、并发压测与容量评估、越权防护与 fail-closed 脱敏；Axure 原型与 PRD 撰写、发版管理

教育与荣誉

EDUCATION

安徽工业大学 软件工程（本科）2022.09 – 2026.07 —— 数据结构、软件架构设计、UML 实例分析、Java 程序设计、数据库原理、计算机系统基础

■ LIC·2025 语言与智能技术竞赛 · 智慧医疗赛道（项目负责人）；全国大学生数学建模竞赛（2024、2025）、美国大学生数学建模竞赛 MCM/ICM（2026）、2025「揭榜挂帅」无人集群专项赛；曾任校园市场经理，从 0 组建 10 人团队半年实现 50 万+ 销售额，任班长期间获「优秀班干部」称号